

PENERAPAN ALGORITMA SVM MENGGUNAKAN SIFT DESKRIPTOR
UNTUK PENGENALAN TULISAN TANGAN PADA KARAKTER
HANACARAKA AKSARA JAWA



Disusun oleh :
Rama Tri Agung
123180053

PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" YOGYAKARTA
2022

BAB II

TINJAUAN LITERATUR

2.1. Landasan Teori

2.1.1. Hanacaraka Aksara Jawa

Aksara jawa atau lebih dikenal dengan Hanacaraka adalah turunan aksara brahmani (berasal dari Hindustan) yang digunakan untuk penulisan berbahasa Jawa, bahasa Makasar, bahasa Madura, bahasa Melayu, bahasa Sunda, bahasa Bali dan bahasa Sasak (Hidayat & Shofa, 2016). Banyak orang yang fasih berbahasa jawa, namun sangat sedikit orang yang bisa membaca aksara Hanacaraka. Penggunaan aksara Hanacaraka secara umum pun juga sangat terbatas, misalnya pada papan penunjuk jalan, papan nama, dan beberapa artikel yang ada pada koran serta majalah. Itupun hanya untuk sekedar mempertahankan keberadaan aksara Hanacaraka agar tidak hilang sama sekali (Setiawan & Sulaiman, 2015). Hanacaraka aksara jawa terdiri dari 20 karakter huruf dasar yaitu seperti pada Gambar 2.1 yang akan digunakan sebagai data penelitian ini.



Gambar 2.1 Karakter Hanacaraka

2.1.2. Pengenalan Karakter Tulisan Tangan

Pengenalan gambar adalah prosedur penting untuk pemrosesan gambar, bagaimana sebuah gambar dipersepsikan sebagai manusia yang mempersepsikan gambar tersebut. Pengenalan tulisan tangan adalah salah satu masalah yang paling dicari dan dipertimbangkan, karena tulisan tangan dapat memungkinkan orang untuk melakukan beberapa pekerjaan, misalnya, pasca-presentasi, pemeriksaan cek bank,

dan penanganan tertulis secara manual pada struktur. Juga dapat berkontribusi besar dalam pengembangan proses otomatisasi dan dapat mengembangkan interaksi antara manusia dan mesin dalam berbagai aplikasi seperti otomatisasi perkantoran dan aplikasi entri data (Ali et al., 2019). Sistem pengenalan berusaha mengenali teks yang diubah menjadi format yang dapat dieksekusi mesin (format digital) yang dapat diproses oleh perangkat lunak pengolahan karakter baik secara *online* maupun *offline*.

2.1.3. *Machine Learning*

Machine Learning merupakan cara untuk memungkinkan suatu mesin memecahkan sebuah masalah yang baru dengan mempelajari pola terhadap cara memecahkan masalah yang telah dipecahkan sebelumnya (Mohaiminul & Sultana, 2018). *Machine Learning* ini merupakan salah satu bidang *Artificial Intelligent* yang memungkinkan sebuah sistem untuk dapat beradaptasi atau belajar melalui data training yang disediakan. Kemampuan kinerja dari *Machine Learning* sangat dipengaruhi oleh algoritma yang digunakan untuk menyelesaikan sebuah masalah (Liu et al., 2017).

Dalam *Machine Learning* ada dua metode yang umum digunakan yaitu *Supervised Learning* dan *Unsupervised Learning*. *Supervised learning* adalah metode di mana data yang digunakan sebelumnya diberikan sebuah label dengan data yang sesuai untuk setiap kelasnya (Saputra et al., 2019). Kemudian *Unsupervised Learning* merupakan metode di mana data pelatihan yang digunakan tidak diberikan label sebagai kelas data, sehingga *Machine Learning* menganalisis data dengan menganalisis kesamaan atau kedekatan pola pada data yang ada. (Chen X. et al., 2021).

2.1.4. Pengolahan Citra

Pengolahan citra (*Image Processing*) adalah sebuah disiplin ilmu yang mempelajari tentang teknik-teknik mengolah citra. Citra yang dimaksud disini adalah gambar diam (foto) maupun gambar bergerak (video) (Kusumanto & Tompunu, 2011). Pengolahan citra berkaitan dengan perbaikan kualitas terhadap suatu gambar (meningkatkan kontras, perubahan warna, restorasi citra), transformasi gambar (translasi, rotasi transformasi, skala, geometrik), melakukan pemilihan citra ciri (*feature images*) yang optimal untuk tujuan analisis, melakukan penyimpanan data yang sebelumnya dilakukan reduksi dan kompresi, transmisi data, dan waktu proses

data (Munantri et al., 2019). Secara umum pengolahan citra digital dapat diartikan sebagai pemrosesan gambar dua dimensi dengan menggunakan komputer. Citra digital merupakan sebuah array (larik) yang berisikan nilai-nilai real maupun kompleks yang dapat direpresentasikan dengan deretan bit tertentu (Munantri et al., 2019).

2.1.5. *Scale Invariant Feature Transform*

SIFT (*Scale Invariant Feature Transform*) telah terbukti berkinerja lebih baik daripada deskriptor lokal lainnya (Mortensen et al. 2005). Diberikan titik fitur, deskriptor SIFT menghitung vektor gradien untuk setiap piksel di lingkungan titik fitur dan membangun histogram arah gradien yang dinormalisasi. Deskriptor SIFT menciptakan lingkungan 16x16 yang dipartisi menjadi 16 subwilayah masing-masing 4x4 piksel. Untuk setiap piksel dalam subwilayah, SIFT menambahkan vektor gradien piksel ke histogram arah gradien dengan mengkuantisasi setiap orientasi ke salah satu dari 8 arah dan memberi bobot kontribusi setiap vektor berdasarkan besarnya. Setiap arah gradien selanjutnya dibobot dengan skala Gaussian = $n/2$ di mana n adalah ukuran lingkungan dan nilai-nilai didistribusikan ke bin tetangga menggunakan interpolasi trilinear untuk mengurangi efek batas saat sampel bergerak di antara posisi dan orientasi (Mortensen et al. 2005). Berikut beberapa proses penting dalam SIFT (Wang et al., 2013) (Hassan et al., 2018):

a. *Scale-space extrema detection*

Proses pertama diawali dengan mendeteksi *points of interest*, atau yang disebut juga *keypoint* pada SIFT. Gambar asli diambil dan menghasilkan urutan gambar blur terus-menerus, kemudian mengubah ukuran gambar asli menjadi 50% dari ukurannya dan menghasilkan gambar blur berulang kali. Citra dikonvolusikan dengan filter *Gaussian* pada skala yang berbeda, kemudian diambil perbedaan dari citra *Gaussian* yang berurutan. *Keypoint* kemudian diambil sebagai maxima/minima dari *Difference of Gaussians* (DoG) yang terjadi pada beberapa skala. Berikut rumus DoG.

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (2.1)$$

Dimana $L(x, y, k\sigma)$ adalah konvolusi dari citra asli $I(x, y)$ dengan *Gaussian Blur* $G(x, y, k\sigma)$ dalam skala $k\sigma$ yaitu

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \quad (2.2)$$

Dan

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (2.3)$$

Nilai k merupakan nilai kontinu dari beberapa nilai skala yang berbeda-beda untuk membandingkan beberapa hasil dari pengurangan konvolusi *Gaussian Blur*.

Setelah gambar DoG diperoleh, *keypoints* diidentifikasi sebagai *local minima/maxima* dari gambar DoG di seluruh skala. Hal ini dilakukan dengan membandingkan setiap piksel dalam gambar DoG dengan delapan tetangganya pada skala yang sama dan sembilan piksel tetangga yang sesuai di setiap skala tetangga. Jika nilai piksel adalah maksimum atau minimum di antara semua piksel yang dibandingkan, maka dipilih sebagai *candidate keypoint*.

b. Keypoint localization

Menemukan *maxima/minima* dalam citra DoG dan menemukan sub piksel *maxima/minima* untuk mendapatkan *keypoints* pada *scale space extreme* di citra DoG. Melakukan pencocokan detail ke data terdekat untuk lokasi, skala, dan rasio kelengkungan utama yang akurat. Informasi ini memungkinkan untuk menolak titik yang kontrasnya rendah (dan karenanya sensitif terhadap *noise*) atau tidak terlokalisasi di sepanjang tepi. Tepi dan area kontras rendah dianggap sebagai poin kunci yang buruk. Penghapusan poin-poin kunci tersebut meningkatkan efisiensi dan ketahanan algoritma. Pendekatan yang mirip dengan *Harris Corner Detector* diterapkan di sini.

c. Orientation assignment

Setiap *keypoint* diberikan satu atau lebih orientasi berdasarkan arah gradien gambar lokal. Ini adalah langkah kunci dalam mencapai invarian terhadap rotasi karena *deskriptor keypoint* dapat direpresentasikan relatif terhadap orientasi ini dan karenanya mencapai invarian terhadap rotasi gambar. Besaran gradien dan orientasi diperoleh dengan menggunakan persamaan. Besaran dan orientasi dihitung untuk semua piksel yang mengelilingi titik-titik kunci. Setelah itu, histogram dapat dibuat.


$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2} \quad (2.4)$$

$$\theta(x, y) = \tan^{-1} \left(\frac{L(x, y + 1) - L(x, y - 1)}{L(x + 1, y) - L(x - 1, y)} \right) \quad (2.5)$$

Citra $L(x, y, \sigma)$ yang dihaluskan *Gaussian* pada skala *keypoint* σ diambil sehingga semua komputasi dilakukan dengan cara *scale-invariant*. Untuk sampel gambar $L(x, y)$ pada skala σ , besaran gradien $m(x, y)$, dan orientasi $\theta(x, y)$, dihitung terlebih dahulu menggunakan rumus diatas.

d. *Keypoint descriptor*

Terakhir, menghitung vektor deskriptor untuk setiap *keypoints* sedemikian rupa sehingga deskriptor sangat unik/berbeda dan sebagian tidak berubah untuk variasi yang tersisa seperti iluminasi, sudut pandang 3D, dll. Dengan representasi ini, dimungkinkan dapat dengan mudah memperoleh fitur yang diperlukan. Untuk melakukannya, matriks 16x16 yang disekitar *keypoints* diatur dan matriks ini dibagi menjadi 16 matriks ukuran 4x4. Di dalam setiap matriks 4x4, besaran gradien dan orientasi dapat diperoleh. Histogram ini dibagi menjadi delapan bin dan jumlah orientasi yang ditambahkan ke bin tergantung pada besaran gradien. Sehingga, setiap titik kunci dideskripsikan oleh $4 \times 4 \times 8 = 128$ dimensi vektor.



Gambar 2.2 Fitur SIFT

2.1.6. *Support Vector Machine*

Support Vector Machine (SVM), adalah salah satu algoritma pembelajaran mesin terbaik, yang diusulkan pada 1990-an dan sebagian besar digunakan untuk pengenalan pola (Pradhan, 2012). Ini juga telah diterapkan pada banyak masalah klasifikasi pola seperti pengenalan gambar, pengenalan ucapan, kategorisasi teks,

deteksi wajah, dan deteksi kartu yang salah, dll. Pengenalan pola bertujuan untuk mengklasifikasikan data berdasarkan pengetahuan apriori atau informasi statistik yang diambil dari data mentah yang merupakan alat yang ampuh dalam pemisahan data di banyak disiplin ilmu. SVM adalah pembelajaran mesin jenis *supevised learning*. algoritma di mana diberikan satu set contoh pelatihan, masing-masing ditandai sebagai milik salah satu dari banyak kategori, algoritma pelatihan SVM membangun model yang memprediksi kategori contoh baru (Pradhan, 2012). SVM memiliki kemampuan yang lebih besar untuk menggeneralisasi masalah, yang merupakan tujuan pembelajaran statistik statistical.

SVM dimodifikasi dalam klasifikasi *non-linear* berdasarkan fungsi kernel. Kernel adalah parameter SVM yang dapat disesuaikan dengan kebutuhan. Pada kasus ini kernel yang digunakan adalah *Radial Basis Function* (RBF) (Kamble & Hegadi, (2017). Sehingga algoritma SVM yang dilakukan seperti berikut. Model yang optimal dari himpunan *hyperplanes* di *data training* dihitung dengan algoritma optimasi SVM (Surinta et al., 2015). Fungsi hipotesis dilakukan dengan rumus berikut.

$$h(x) = \text{sign}(\theta^T f) \quad (2.6)$$

Dengan θ adalah bobot dari fungsi dan f sebagai fungsi kernel yang digunakan dengan $f_0 = 1$. Berikut rumus kernel RBF yang digunakan.

$$f_i = K(x, x'_i) \quad (2.7)$$

$$K(x, x') = \exp(-\gamma \|x, x'\|^2), \quad \gamma > 0 \quad (2.8)$$

Nilai parameter yang besar dari γ dapat menyebabkan *overfitting* karena bertambahnya jumlah *support vector*. Dalam kasus klasifikasi *multiclass*, perhitungan dilakukan sebanyak K kelas sehingga nilai prediksi akhir berbentuk vektor dengan panjang K. Dan nilai bobot akan sebanyak K*n fitur.

Untuk menghitung parameter bobot (θ), algoritma SVM meminimalkan *cost function* seperti berikut.

$$J(\theta) = \frac{1}{2} \theta^T \theta + C \sum_{i=1}^m y_i \text{cost}_1(\theta^T f_i) + (1 - y_i) \text{cost}_0(\theta^T f_i) \quad (2.9)$$

Di mana parameter C sebagai pengendali pertukaran antara kesalahan pelatihan dan generalisasi atau sering disebut juga parameter *regularization*.

2.2. Penelitian Terdahulu

Beberapa penelitian yang telah dilakukan sebelumnya membahas tentang pengenalan tulisan tangan karakter hanacaraka aksara jawa dengan berbagai metode yang diimplementasikan dan penelitian lainnya juga telah membahas pengenalan tulisan tangan dengan objek karakter yang berbeda menggunakan metode SIFT Deskriptor.

Penelitian yang telah diusulkan (Wibowo et al., 2018) dengan menggunakan metode yaitu *Convolutional Neural Network* (CNN) oleh widowo dkk. penelitian ini menguji algoritma CNN yang merupakan salah satu jenis model *discriminative deep-learning* yang sangat luas digunakan untuk klasifikasi berdasarkan *supervised learning*. Dalam melakukan klasifikasi tulisan tangan penelitian ini menggunakan dataset yang sangat besar berjumlah sebanyak 11500 total karakter dengan 575 karakter tiap jenis karakter hanacaraka yang berjumlah 20 buah. *Dataset* tersebut diolah dengan membuat dua *modelling extraction* yaitu Model 1 memiliki 3 2D *Convolution Layer*, 3 *pooling layer*, 1 *fully connected layer* dan Model 2 hanya memiliki 1 *fully connected layer*. Kemudian untuk mengurangi *error* dan mengatur parameter seperti *momentum*, *learning rate*, *regularization method*, dan *activation function* menggunakan *Stochastic Gradient Descent algorithm*. Hasil penelitian menunjukkan angka yang memuaskan dengan tingkat akurasi sebesar 94.57%, presisi 94.75%, recall 94.57%, dan F1 score 94.66%.

Penelitian lainnya (Dewa et al., 2018) diusulkan juga menggunakan CNN dan MLP. Pada penelitian ini perangkat lunak yang dikembangkan memanfaatkan deteksi kontur dan deteksi tepi *Canny* menggunakan pustaka OpenCV terhadap citra karakter Aksara Jawa untuk proses segmentasi. Data yang digunakan sebanyak 2000 karakter hanacaraka dan Modul CNN selanjutnya melakukan proses klasifikasi terhadap citra yang telah disegmentasi ke dalam 20 kelas berukuran 28x28 piksel. Untuk evaluasi, kinerja CNN dibandingkan dengan kinerja dari model *Multilayer Perceptron* (MLP) dari sisi akurasi klasifikasi dan waktu latih. Hasil pengujian menunjukkan akurasi dari model CNN mampu mengungguli akurasi dari model MLP yaitu sebesar 89% meskipun CNN membutuhkan waktu latih yang lebih lama dibandingkan dengan MLP.

Rismiyati, et al. (2017) juga melakukan penelitiannya menggunakan CNN dan DNN. Klasifikasi dilakukan dengan menggunakan 2470 gambar dataset karakter

hanacaraka dengan input gambar berdimensi 32x32 piksel, selanjutnya dilakukan pengujian model dengan 10 *fold cross validation* menghasilkan performa akurasi yang cukup baik sebesar 70.22% untuk model CNN dan 64.41% untuk model DNN.

Selain menggunakan CNN terdapat penelitian dari (Sari et al., 2018) dengan objek yang sama pada penelitian sebelumnya namun menggunakan metode KNN dengan *Feature Extraction Roundness* dan *Eccentricity*. Meskipun metode KNN yang dikenal sebagai metode klasifikasi dengan akurasi lebih kecil dari CNN namun pada penelitian kekurangan dari algoritma KNN dapat ditutupi dengan menggunakan fitur ekstraksi *Roundness* dan *Eccentricity*. Sejumlah 240 data training yang digunakan pada penelitian dengan beberapa tahapan preprocessing yaitu proses *cropping*, *binary*, *converting* kedalam *negative image*, *filtering* dengan *median filter* dan terakhir *dilation*. Dengan pengukuran jarak antar data menggunakan KNN dengan nilai K sebesar 3 menghasilkan akurasi yang cukup optimal yaitu sebesar 87.5%.

Penelitian pada objek hanacaraka aksara jawa berikutnya diusulkan oleh (Risdiyati et al., 2018) menggunakan algoritma *Support Vector Machine* dengan HOG dan *Zone Base Features*. Data yang digunakan pada penelitian ini sebanyak 2459 dan kemudian melakukan *preprocessing* dan *skeletonization* untuk menghilangkan ruang putih di sekitar gambar, mengonversi menjadi gambar biner, dan mendapatkan kerangka objek biner. Performa dari fitur HOG dan *Zoning* tersebut akan dibandingkan untuk pengklasifikasian karakter hanacaraka. Dua jenis input akan digunakan untuk masing-masing ekstraktor fitur, biner dan kerangka citra karakter. Hasil percobaan menunjukkan bahwa fitur HOG mampu menunjukkan akurasi yang lebih tinggi dibandingkan dengan fitur berbasis zona sederhana (88,45%). Akurasi terbaik untuk HOG dicapai dengan menggunakan input biner. Di sisi lain, meskipun sederhana, fitur berbasis zona mampu mencapai akurasi 81,98% dengan menggunakan input kerangka.

Widiarti & Wastu (2009) mengusulkan penelitian mengenai pengenalan tulisan tangan aksara jawa dengan menggunakan metode *Hidden Markov Model* (HMM). Penelitian menggunakan dataset yang cukup kecil yaitu sejumlah 1000 *record* (800 *data training* dan 200 *data testing*). Beberapa tahapan yang dilakukan yaitu *preprocessing* yang meliputi *filtering background noise*, transformasi gambar menjadi *binary image*, dan *resize image* menjadi 72x72 *pixel*; kemudian fitur ekstraksi dilakukan dengan menggunakan ekstraksi *Horizontal & Vertical Vector* dengan

memecahkan menjadi empat percobaan yaitu membagi karakter ke dalam 1 *horizontal vector* (1H), 2 *horizontal vector* (2H), 1 *vertical vector* (1V), dan 2 *vertical vector* (2V); selanjutnya *modelling* data menggunakan HMM dengan jumlah *state* yang bervariasi 15-22 *state*; terakhir pada *testing* yang dilakukan dengan menggunakan *k-fold cross validation* untuk mencari akurasi yang paling optimal. Akurasi optimal yang didapatkan pada penelitian ini sebesar 85.7% dengan menggunakan 16 *state* dan fitur ekstraksi 1V.

Rasyidi et al. (2021) juga telah mengusulkan pengenalan tulisan tangan aksara jawa dengan menggunakan metode *Random Forest*. Pada penelitian ini data yang diambil sebesar 6000 gambar dan dibagi menjadi dua yaitu 70% *data training* dan 30% *data testing*, kemudian data tersebut dilakukan proses *data augmentation* dengan kombinasi *rotation image* dan *shear image* sehingga menghasilkan data sebesar 21000 data training dan 9000 data testing. Kemudian pada *preprocessing* dilakukan *binarization images*, *cropping*, dan *resizing* menjadi 32x32 piksel. Selain tiga hal tersebut terdapat proses tambahan yaitu kombinasi terhadap *thinning* dan HOG. Pada *training model* dengan menggunakan *random forest* beberapa parameter yang digunakan akan diuji dengan metode *grid search* dan *3-fold cross validation* pada parameter *Impurity Measure* (gini, entropy) dan jumlah *tree* (bervariasi 200-2000). Terakhir tahap uji dilakukan menggunakan *data testing* menghasilkan nilai yang optimal yaitu *accuracy* 97%, *precision* 97%, dan *recall* 97% dengan kombinasi tanpa menggunakan proses *thinning* dan HOG serta nilai parameter *impurity measure* yaitu gini dan jumlah *tree* yaitu 1800.

Metode KNN dan HOG juga dapat dilakukan dalam pengenalan tulisan tangan aksara jawa (Susanto et al., 2021). Penelitian ini menggunakan 1000 data citra karakter aksara jawa yang dibagi menjadi 20 kelas. Proses *preprocessing* yang dilakukan yaitu *grayscale*, *thresholding*, *median filter*, dan *size normalization*, selanjutnya fitur ekstraksi diterapkan menggunakan HOG. Proses *training model* menggunakan metode KNN dengan nilai K yang paling optimal adalah 1 serta rasio dari pemisahan *dataset training* dan *testing* yaitu 80:20, sehingga menghasilkan akurasi terbaik sebesar 98,5%. Tahap testing dilakukan dengan melakukan kombinasi nilai K dan rasio pemisahan *dataset*. Perbandingan hasil model KNN-Median Filter-HOG yang diperoleh meningkat sekitar 4% daripada model yang tidak menggunakan fitur ekstraksi dan *median filter*.

Kemudian terdapat penelitian lainnya yang sedikit berbeda menggunakan *Optical Character Recognition* dengan bantuan *Tesseract Tools* (Robby et al., 2019). Penelitian ini mengambil dua tipe data yang akan digunakan yaitu 5880 data tulisan tangan dan 260 data digital, data tersebut terdiri dari 120 kelas dari karakter aksara jawa yang dilengkapi dengan masing-masing tanda baca ‘a-i-u-e-o-è’ (sandangan). Kedua asal data tersebut dikombinasikan sebagai proses training yang dilakukan. Beberapa proses *preprocessing* diterapkan dalam penelitian ini yaitu rotasi citra, pengisian label, menghilangkan *noise*, dan *sharpening*. Kemudian proses *training* dilakukan menggunakan teknik *Neural-Network API* dari *Tesseract OCR Tool*. Akurasi tertinggi (97,50%) yang dicapai oleh model dicapai dengan menggabungkan *single boundary box* untuk seluruh bagian karakter dan *separate boundary boxes* di karakter dan bagian sandangannya.

Penelitian berikutnya dengan objek yang berbeda yaitu pada aksara sasak (tidak berbeda jauh dengan aksara jawa) diusulkan oleh Yulianti et al. (2019) menggunakan SVM dan *Moment Invariant* sebagai ekstraksi fitur. Penelitian ini menggunakan *dataset* sebesar 2700 data yang dibagi menjadi 1800 data latih dan 900 data uji. Dalam *preprocessing image* beberapa hal yang dilakukan yaitu *greyscaling*, *binarization*, *cropping*, *resizing* menjadi 28x28 piksel, dan *thinning*. Kemudian *Moment Invariant* melakukan fungsi *non-linear* yang *invariant* terhadap rotasi, translasi dan skala dalam *moment* geometri citra yang menghasilkan tujuh nilai *moment invariant*. Modelling data dilakukan dengan menggunakan metode *SVM Tree Structure* untuk mengenali 18 kelas aksara sasak. Terakhir pada pengujian dilakukan dengan menggunakan *k-fold cross validation* dengan hasil akurasi yang optimal sebesar 92,52% dengan menggunakan 112 fitur dari *moment invariant*.

Selain pada penelitian menggunakan objek karakter hanacaraka, terdapat penelitian lainnya dengan objek berbeda yang dilakukan oleh (Surinta et al., 2015) yang menggunakan metode KNN dan SVM dengan menggunakan *Local Gradient Feature* pada beberapa objek karakter Thai, Bangla, dan Latin. *Local Gradient Feature* terdiri dari dua fitur yaitu HOG dan SiftD. *Dataset* yang digunakan pada penelitian ini berupa 68 kelas karakter Thai 13130 *data training* dan 1360 *data testing*, 10 kelas digit Thai 8055 *data training* dan 1500 *data testing*, 45 kelas karakter Bangla 4627 *data training* dan 900 *data testing*, 10 kelas digit Bangla 9161 *data training* dan 1500 *data testing*, 25 kelas karakter Latin 26392 *data training* dan 11287 *data testing*,

10 kelas digit Latin 1637 *data training* dan 880 *data testing*. Sebelum melakukan klasifikasi dataset dilakukan proses *preprocessing* berupa gambar tulisan tangan diubah menjadi skala *greyscale* dan dinormalisasi menjadi gambar ukuran tetap. Ada dua resolusi ruang piksel yang digunakan dalam penelitian ini yaitu ruang piksel 28x28 dan 36x36. Hasilnya menunjukkan bahwa deskriptor fitur gradien lokal secara signifikan mengungguli secara langsung menggunakan intensitas piksel dari gambar. Fitur HOG dan siftD memberikan performa yang sangat baik dan signifikan dengan akurasi mendekati 100%. Ketika deskriptor fitur yang diusulkan digabungkan dengan SVM, akurasi yang sangat tinggi diperoleh pada kumpulan data tulisan tangan Thailand (karakter dan angka), kumpulan data tulisan tangan Latin (karakter dan angka), dan kumpulan data angka tulisan tangan Bangla.

Penelitian lainnya yang berbeda dilakukan oleh Narang et al. (2020) dengan melakukan pengenalan tulisan tangan pada karakter Devanagari menggunakan SIFT dan *Gabor Filter* sebagai teknik fitur ekstraksi serta SVM sebagai teknik klasifikasinya. Pada penelitian ini menggunakan dataset karakter Devanagari sejumlah 5484 sampel dengan 33 kelas karakter. Dari data karakter tersebut dinormalisasi ke ukuran karakter 64x64 piksel dengan menggunakan metode *nearest neighbourhood interpolation* untuk pemrosesan dan pengenalan lebih lanjut. Selanjutnya fitur ekstraksi dilakukan terpisah oleh SIFT dan Gabor untuk dibandingkan, terakhir klasifikasi dilakukan menggunakan SVM dengan kernel yang beragam (linier, poly, RBF, dan sigmoid). Hasil penelitian tersebut dilakukan dengan beberapa testing dari variasi parameter yang dimasukkan juga menggunakan *k-fold cross validation* dan menunjukkan bahwa nilai performa akurasi terbaik diperoleh pada kombinasi metode dari penggunaan *5-fold cross validation*, Gabor, dan poly-SVM dengan nilai akurasi sebesar 91.39%. Disisi lain penggunaan SIFT mendapatkan akurasi awal sebesar 65.97% menggunakan RBF-SVM.

Kemudian, penelitian berbeda mengenai pengenalan kata tulisan tangan bahasa Arab menggunakan SIFT dan SVM dilakukan oleh Hassan et al. (2019). Penelitian tersebut menggunakan data kata-kata dalam bahasa Arab sebanyak 2072 sampel data latih dan 868 sampel data uji. Proses penelitian ini diawali dengan *preprocessing data* yaitu melakukan konversi warna RGB pada citra menjadi warna abu-abu, kemudian fitur ekstraksi dilakukan dengan menggunakan metode pendekatan SIFT, selanjutnya sebelum klasifikasi dilakukan metode *K-Means* dan FINN akan diterapkan sebagai

feature selection pada data input sehingga fitur yang digunakan menjadi lebih baik dari yang sebelumnya, tahap terakhir dilakukan klasifikasi data dengan menggunakan SVM. Hasil penelitian menunjukkan bahwa dengan menggunakan SIFT dan SVM serta sedikit bantuan *feature selection* memperoleh nilai akurasi yang tinggi yaitu sebesar 99.08%.

Dengan metode KNN-SIFT juga dapat diusulkan dalam penelitian mengenai *Document Script Identification* (Rajput & Ummapure, 2017). Penelitian ini bertujuan untuk mengenali bahasa dalam sebuah dokumen tulisan tangan diantaranya bahasa Inggris, Kanada, dan Devanagari (Hindi). Terdapat 240 data dokumen Kanada, 240 Hindi, dan 240 Inggris digunakan dalam melakukan *training* model KNN. Sebelumnya data gambar tersebut dilakukan *preprocessing* yaitu segmentasi baris/kata pada kalimat dalam dokumen, menghilangkan *noise* dengan *median filter*, normalisasi ukuran gambar menjadi 256x256 piksel, dan *binarization*. Pada tahap testing dilakukan tiga tipe yaitu pada 210 teks 2 kata, 210 teks 3 kata, dan 300 teks lebih dari 3 kata, hasil pengujian menunjukkan model yang paling optimal yaitu KNN dengan nilai K adalah 1 memiliki akurasi sebesar 97,65% klasifikasi 2 bahasa dan 96,71% klasifikasi 3 bahasa. Rata-rata nilai akurasi mencapai 97,18%.

Sriwathsan et al. (2020) mengusulkan penelitiannya tentang *Signature Recognition* menggunakan metode SVM dan fitur SIFT/SURF. Penelitian ini menggunakan 1600 *signature* data dengan pemisahan 800 *data training* dan 800 *data testing*. *Preprocessing* yaitu diterapkan pada gambar data yaitu *binarization*, *noise removal*, dan *boundary extraction*. Kemudian ekstraksi fitur dicoba pada SIFT dan SURF untuk melihat perbandingan hasil yang diperoleh, tidak hanya itu *K-Means*, *codebook generation*, dan *quantization* data juga dilakukan setelahnya. Terakhir tahapan *modelling* dilakukan dengan SVM. *Testing* dilakukan dengan menggunakan *10-fold cross validation* dan melakukan *tuning parameter* dari SVM serta *K-Means*. Hasil terbaik diperoleh pada SIFT mendapat akurasi sebesar 68% sedangkan SURF memperoleh akurasi sebesar 96,87%, hasil tersebut diperoleh dari beberapa percobaan yang dilakukan.

Berikutnya oleh Wang et al. (2015) mengusulkan penelitian tentang *License Plate Recognition* hanya menggunakan SIFT. Penelitian ini mengambil 700 gambar *data training* dan 100 gambar *data testing*. Selain menggunakan SIFT terdapat teknik lainnya yaitu *candidate filtration*, *tilt correction*, *character segmentation*, dan

character recognition. Semua teknik tersebut akan dibungkus dengan metode fitur Sift. Hasil penelitian yang dilakukan memperoleh performa akurasi pada *chinese character recognition* 95,4%, *noise region recognition* 100%, dan total keseluruhan pengenalan 96,0%.

Mirip dengan sebelumnya penelitian yang diusulkan oleh Doush & AL-Btoush (2017) menggunakan metode SIFT sebagai metode klasifikasi dari *Currency Recognition*. Penelitian ini menggunakan 100 *data training* dan 400 *data testing* yang diambil dari kamera *handphone* sebanyak 20 kelas uang kertas maupun logam. Data citra dilakukan kompresi gambar dan *crop background* sebelum *training*. Penelitian ini menguji dua kasus yaitu menggunakan pengenalan pada gambar yang berwarna dan pengenalan pada gambar yang hitam putih. Hanya dengan menggunakan SIFT hasil performa akurasi penelitian menunjukkan pada gambar berwarna yaitu 71% uang kertas, 25% uang logam dan pada gambar hitam putih yaitu 53% uang kertas, 20% uang logam.

Face Recognition menggunakan SIFT & SURF diusulkan oleh Gupta et al. (2020). Penelitian ini menggunakan beberapa *dataset* yang berasal dari Yale2B, *Face* 94, M2VTS, ORL, dan FERET dengan rasio pembagian *data training* dan *data testing* sebesar 80%:20%. Beberapa *preprocessing* dilakukan yaitu *face edge detection*, *segmentation*, dan *localization*. Selanjutnya fitur ekstraksi oleh SIFT dan SURF dengan beberapa kombinasi percobaan pada ukuran dimensi vektor yaitu 32, 64. Terakhir klasifikasi hasil gambar menggunakan metode *Decision Tree & Random Forest*. Pengujian mengambil performa pada nilai *accuracy*, *true-positive rate*, *false-positive rate*, dan *area under the curve*. Hasil akurasi terbaik yang diperoleh yaitu 99,7% pada kombinasi metode SIFT(64) + SURF(32) *Random Forest* dan *dataset* Yale2B.

Penelitian lainnya mengenai pengenalan tulisan tangan dengan objek karakter Marathi diusulkan oleh Kamble & Hegadi (2017). Penelitian ini menggunakan data yang besar yaitu 17271 data angka yang berasal dari U. Bhattacharya dan B.B. Chaudhuri kemudian 31320 jumlah data miliki sendiri, dengan kombinasi dari 4800 huruf vokal, 6400 huruf konsonan, 20120 angka. *Preprocessing* dan ekstraksi fitur dilakukan dengan menghitung *area*, *perimeter*, *eccentricity*, *orientation*, dan nilai *Euler* berdasarkan komponen piksel citra. Selanjutnya klasifikasi dilakukan oleh

metode SVM dan KNN dengan variasi *5-fold validation*. Hasil performa akurasi yang diperoleh menggunakan data milik sendiri sebesar 88,52% SVM dan 80,25% KNN.

Penelitian terakhir yang diusulkan mengenai pengenalan huruf dan angka menggunakan *Hybrid DWT-DCT* dengan metode klasifikasi KNN dan SVM (Ghadekar et al., 2018). Penelitian ini dilakukan secara terpisah dimana pertama klasifikasi dilakukan pada angka dengan jumlah data 60000 *training* dan 10000 *testing*, sedangkan pada klasifikasi huruf memiliki jumlah data 128000 *training* dan 20800 *testing*. Fitur ekstraksi dilakukan dengan menggabungkan dua metode yaitu DWT untuk mendapatkan nilai *approximation matrix* dan DCT untuk mendapatkan nilai koefisien kemudian hasil fitur disimpan dan digunakan dalam klasifikasi. Klasifikasi menggunakan metode KNN dengan nilai K yaitu 5 dan SVM. Hasil klasifikasi pertama pada digit memperoleh akurasi 97,33% KNN dan 97,74% SVM kemudian klasifikasi kedua pada huruf memperoleh akurasi 88,56% KNN dan 89,51% SVM.

Dari penelitian-penelitian yang telah dijabarkan sebelumnya, maka dapat diringkaskan menjadi suatu tabel state of the art yang dapat dilihat pada **Tabel 2.1** berikut ini.

Tabel 2.1 State of the art

No	Penulis	Judul	Metode	Hasil
1	Wibowo et al. (2018)	<i>Handwritten Javanese Character Recognition using Discriminative Deep Learning Technique</i>	CNN	Hasil penelitian menggunakan metode CNN menunjukkan angka yang memuaskan dengan tingkat akurasi sebesar 94.57%, presisi 94.75%, <i>recall</i> 94.57%, dan <i>F1 score</i> 94.66%.
2	Dewa et al. (2018)	<i>Convolutional Neural Networks for Handwritten Javanese Character Recognition</i>	CNN dan MLP	Hasil pengujian menunjukkan akurasi dari model CNN mampu mengungguli akurasi dari model MLP yaitu sebesar 89% meskipun CNN membutuhkan waktu latih yang lebih lama dibandingkan dengan MLP.
3	Sari et al. (2018)	<i>Roundness and Eccentricity Feature Extraction for Javanese Handwritten Character Recognition based on K-Nearest Neighbor</i>	KNN dengan <i>Feature Extraction Roundness</i> dan <i>Eccentricity</i>	Dengan menggunakan dataset yang cukup kecil sebesar 240 data klasifikasi KNN yang dibantu oleh <i>Feature Extraction Roundness</i> dan <i>Eccentricity</i> dengan nilai K sebesar 3 menghasilkan akurasi yang cukup optimal yaitu sebesar 87.5%.
4	Rismiyati et al. (2018)	<i>HOG and Zone Base Features for Handwritten Javanese Character Classification</i>	SVM using HOG or <i>Zone Base Features</i>	Hasil percobaan menunjukkan bahwa fitur HOG mampu menunjukkan akurasi yang lebih tinggi dibandingkan dengan fitur berbasis zona sederhana (88,45%). Di sisi lain, meskipun sederhana, fitur berbasis

				zona mampu mencapai akurasi 81,98%.
5	Widiarti & Wastu (2009)	<i>Javanese Character Recognition Using Hidden Markov Model</i>	HMM dengan fitur ekstraksi <i>Horizontal & Vertical Vector</i>	Hasil dari penelitian menunjukkan bahwa akurasi yang optimal didapatkan dari jumlah <i>state</i> yaitu 16 dan fitur ekstraksi pada 1 <i>vertical vector</i> (1V) sehingga meraih akurasi sebesar 85,7%.
6	Yulianti et al. (2019)	Pengenalan Pola Tulisan Tangan Suku Kata Aksara Sasak Menggunakan Metode <i>Moment Invariant</i> dan <i>Support Vector Machine</i>	SVM dengan <i>Moment Invariant</i>	Hasil penelitian dengan melakukan <i>preprocessing</i> (<i>greyscaleing, binarization, cropping, resizing 28x28, dan thinning</i>), <i>moment invariant</i> sebanyak 112 fitur, dan SVM mendapatkan hasil akurasi optimal sebesar 92,52%.
7	Rasyidi et al. (2021)	<i>Classification of handwritten Javanese script using random forest algorithm</i>	<i>Random Forest</i>	Hasil penelitian menunjukkan bahwa dengan menggunakan data yang banyak sebesar 21000 <i>data training</i> dan 9000 <i>data testing</i> menghasilkan nilai akurasi, presisi, dan <i>recall</i> yang tinggi sebesar 97,7% tanpa menggunakan proses <i>thinning</i> dan HOG serta parameter <i>impurity measure</i> yaitu <i>gini</i> dan jumlah <i>tree</i> yaitu 1800.
8	Rismiyati et al. (2017)	<i>Deep Learning for Handwritten Javanese Character Recognition</i>	CNN & DNN	Klasifikasi berhasil dilakukan dengan menggunakan 2470 dataset ukuran 32x32 piksel memperoleh akurasi 70,22% model CNN dan 64,41% model DNN.
9	Susanto et al. (2021)	<i>Histogram of Gradient in K-Nearest Neighbor for Javanese Alphabet Classification</i>	KNN & HOG	Peningkatan akurasi terjadi sekitar 4% ketika menggunakan model KNN-median filter-HOG pada 1000 data karakter aksara jawa. Akurasi tertinggi mencapai 98,5% dengan nilai K adalah 1 dan rasio pembagian <i>dataset</i> 80:20.
10	Robby et al. (2019)	<i>Implementation of Optical Character Recognition using Tesseract with the Javanese Script Target in Android Application</i>	Neural Network API Tesseract OCR	OCR dengan menggunakan data tulisan tangan dan data digital pada aksara jawa menerapkan API Tesseract OCR menghasilkan nilai akurasi tertinggi 97.5%. Beberapa <i>preprocessing</i> yang dilakukan yaitu rotasi, <i>labelling, noise removal, dan sharpening</i> .
11	Surinta et al. (2015)	<i>Recognition of handwritten characters using local gradient feature descriptors</i>	KNN dan SVM menggunakan <i>Local Gradient Feature</i>	Hasil menunjukkan bahwa deskriptor fitur gradien lokal secara signifikan mengungguli secara langsung menggunakan intensitas piksel dari gambar. Fitur HOG dan SIFT memberikan performa yang sangat baik dan signifikan ketika digabungkan dengan metode SVM dengan akurasi mendekati 100%.
12	Narang et al. (2020)	<i>On the recognition of Devanagari ancient handwritten characters using SIFT and Gabor features</i>	SVM dengan SIFT dan Gabor	Dengan dataset sebesar 5484 sampel untuk 33 kelas karakter Devanagari, <i>preprocessing</i> hanya normalisasi ukuran gambar, fitur ekstraksi SIFT dan Gabor, serta klasifikasi SVM memperoleh nilai akurasi sebesar 91,39% untuk Gabor & Poly-SVM dan 65,97% untuk SIFT & RBF-SVM.
13	Hassan et al. (2019)	<i>Arabic Handwriting Word Recognition Based on Scale</i>	SVM dan SIFT	Hasil penelitian yang dilakukan dengan menggunakan 2072 data latih dan beberapa tahapan yaitu <i>preprocessing</i>

		<i>Invariant Feature Transform and Support Vector Machine</i>		untuk konversi warna, fitur ekstraksi menggunakan SIFT, bantuan <i>feature selection</i> K-Means & FINN, dan klasifikasi menggunakan SVM menghasilkan akurasi tinggi sebesar 99.08%.
14	Rajput & Umapure (2017)	<i>Script Identification from Handwritten Documents using SIFT Method</i>	KNN & SIFT	Topik <i>Script Identification</i> berhasil dilakukan dengan menggunakan KNN-SIFT dengan 3 bahasa sebagai target (Inggris, Kanada, Devanagari). Dengan parameter K adalah 1 memperoleh akurasi sebesar 97,65% untuk 2 bahasa, 96,71% untuk 3 bahasa, dan 97,18% rata-rata semuanya.
15	Sriwathsan et al. (2020)	<i>Offline Handwritten Signature Recognition Based on SIFT and SURF Features Using SVMs</i>	SVM & SIFT/ SURF	1600 signature data berhasil dilakukan pengenalan dengan metode SVM dan SIFT/SURF sebagai ekstraksi fitur. Pada SIFT memperoleh akurasi 68% sedangkan SURF 96,87% dengan <i>10-fold cv</i> dan <i>tuning parameter</i> . Sebelumnya juga dilakukan <i>preprocessing binarization, noise removal, boundary extraction</i> .
16	Wang et al. (2015)	<i>License plate recognition based on SIFT feature</i>	SIFT	Hasil penelitian mengenai <i>License Plate Recognition</i> daerah Cina dengan hanya menggunakan metode SIFT dan 800 data memperoleh akurasi pada <i>chinese character recognition</i> 95,4%, <i>noise region recognition</i> 100%, dan total keseluruhan pengenalan 96,0%.
17	Doush & AL-Btoush (2017)	<i>Currency recognition using a smartphone: Comparison between color SIFT and gray scale SIFT algorithms</i>	SIFT	Hanya dengan menggunakan SIFT pengenalan uang berhasil dilakukan dengan tingkat akurasi pada gambar berwarna yaitu 71% uang kertas, 25% uang logam dan pada gambar hitam putih yaitu 53% uang kertas, 20% uang logam.
18	Gupta et al. (2020)	<i>2D-human face recognition using SIFT and SURF descriptors of face's feature regions</i>	<i>Decision Tree & Random Forest, SIFT & SURF</i>	Hasil penelitian <i>face recognition</i> memperoleh akurasi terbaik 99,7% pada <i>dataset Yale2B</i> dengan kombinasi SIFT(64) + SURF(32) dan <i>Random Forest</i> . <i>Preprocessing</i> dilakukan yaitu <i>face edge detection, segmentation, dan localization</i> .
19	Kamble & Hegadi (2017)	<i>Comparative Study of Handwritten Marathi Characters Recognition Based on KNN and SVM Classifier</i>	SVM & KNN	Penelitian pada pengenalan karakter Marathi dengan jumlah data 31320 gabungan dari seluruh huruf memperoleh hasil akurasi sebesar 88,52% SVM dan 80,25% KNN. Ekstraksi fitur juga dilakukan yaitu menghitung <i>eccentricity, orientation</i> dan <i>area</i> .
20	Ghadekar et al. (2018)	<i>Handwritten Digit and Letter Recognition Using Hybrid DWT-DCT with KNN and SVM Classifier</i>	SVM & KNN, Hybrid DWT-DCT	Hasil penelitian klasifikasi angka dan huruf berhasil dengan data yang sangat besar, dengan bantuan fitur ekstraksi dari <i>Hybrid DWT-DCT</i> metode klasifikasi KNN dan SVM dapat berjalan dengan baik, sehingga memperoleh nilai akurasi pada klasifikasi pertama (digit) 97,33% KNN dan 97,74% SVM, sedangkan pada klasifikasi kedua (huruf) 88,56% KNN dan 89,51% SVM.

Berdasarkan tinjauan penelitian-penelitian sebelumnya, maka penelitian ini akan memiliki kesamaan dalam hal tema penelitian yaitu pengenalan tulisan tangan dan dengan objek yang sama yaitu pada karakter hanacaraka aksara jawa. Penelitian ini akan memiliki perbedaan dari sisi metode yang digunakan, serta hasil dari penelitian.

Beberapa perbedaan dengan penelitian sebelumnya terbagi menjadi dua yaitu pertama dengan metode yang berbeda yang digunakan seperti CNN, HMM, KNN, SVM, dan lainnya dengan beberapa fitur ekstraksi tersendiri sendiri (Dewa et al., 2018) (Rasyidi et al., 2021) (Rismiyati et al., 2018) (Sari et al., 2018) (Widiarti & Wastu, 2009) (Susanto et al., 2021), dan yang kedua menggunakan metode fitur ekstraksi yang sama namun berbeda dalam objek dan metode klasifikasi yang digunakan seperti dari (Surinta et al., 2015) dengan objek Thai, Bangla, Latin metode KNN & SVM, lalu dari (Hassan et al., 2019) dengan objek Arabic metode SVM, kemudian dari (Narang et al., 2020) dengan objek Devanagari metode SVM, dan terakhir dari (Sriwathsan et al., 2020) dengan objek tanda tangan metode SVM.

Dari beberapa perbandingan penelitian sebelumnya, terdapat permasalahan pada pengenalan tulisan tangan karakter hanacara terhadap jumlah *data training* yang digunakan dan tingkat akurasi yang diperoleh, sehingga penelitian ini menggunakan metode SVM yang merupakan metode paling efektif dalam klasifikasi, memiliki akurasi yang cukup tinggi (Thamilselvana & Sathiaseelan, 2015), tidak memiliki masalah dalam overfitting (Rajesh et al., 2016), dan tidak membutuhkan jumlah dataset yang sangat besar (Rismiyati et al., 2018).

Namun hanya dengan metode SVM sulit untuk meraih akurasi klasifikasi yang tinggi diatas 90%, oleh sebab itu penelitian ini menggunakan metode fitur ekstraksi tambahan yaitu SIFT untuk membantu meningkatkan akurasi klasifikasi, metode SIFT ini telah dilakukan oleh (Surinta et al., 2015) (Hassan et al., 2019) (Narang et al., 2020) dan terbukti memiliki akurasi yang tinggi.

DAFTAR PUSTAKA

- Ali A., Suresha, M., & Ahmed, M. (2019). Different Handwritten Character Recognition Methods: A Review. 2019 Global Conference for Advancement in Technology, GCAT 2019 (pp. 1-8). Bangalore: IEEE.
- Chen, X., Jin, Z., Wang, Q., Yang, W., Liao, Q., & Meng, H. (2021). Unsupervised visual feature learning based on similarity guidance. *Neurocomputing*, xxxx.
- Dewa, C. K., Fadhillah, A. L., & Afiahayati, A. (2018). Convolutional Neural Networks for Handwritten Javanese Character Recognition. *Indonesian Journal of Computing and Cybernetics Systems*, 12(1), 83-94.
- Doush, I. A., & AL-Btoush, S. (2017). Currency recognition using a smartphone: Comparison between color SIFT and gray scale SIFT algorithms. *Journal of King Saud University – Computer and Information Sciences*, 29(4), 484-492.
- Ghadekar, P., Ingole, S., & Sonone, D. (2018). Handwritten Digit and Letter Recognition Using Hybrid DWT-DCT with KNN and SVM Classifier. Fourth International Conference on Computing Communication Control and Automation (pp. 1-6). Pune: IEEE.
- Gupta, S., Thakur, K., & Kumar, M. (2020). 2D-human face recognition using SIFT and SURF descriptors of face's feature regions. *The Visual Computer*, 37, 447–456.
- Hassan, A. K. A., Mahdi, B. S., & Mohammed, A. A. (2019). Arabic Handwriting Word Recognition Based on Scale Invariant Feature Transform and Support Vector Machine. *Iraqi Journal of Science*, 60(2), 381-387.
- Hidayat, A. & Shofa, R. N. (2016). Self Organizing Maps (Som) Suatu Metode Untuk Pengenalan Aksara Jawa. *Jurnal Siliwangi Sains Teknologi*, 2(1), 64-70.
- Kamble, P. M., & Hegadi, R. S. (2017). Comparative Study of Handwritten Marathi Characters Recognition Based on KNN and SVM Classifier. *Recent Trends in Image Processing and Pattern Recognition*, 709, 93-101.
- Kusumanto, RD. & Tompunu, A. N. (2011). Pengolahan Citra Digital Untuk Mendeteksi Obyek Menggunakan Pengolahan Warna Model Normalisasi Rgb. *Seminar Nasional Teknologi Informasi & Komunikasi Terapan 2011*. Palembang: Semantik.

- Liu, Y., Bi, J. W., & Fan, Z. P. (2017). Multi-class sentiment classification: The experimental comparisons of feature selection and machine learning algorithms. *Expert Systems with Applications*, 80, 323–339.
- Mohaiminul, M., & Sultana, N. (2018). Comparative Study on Machine Learning Algorithms for Sentiment Classification. *International Journal of Computer Applications*, 182(21), 1– 7.
- Mortensen, E. N., Deng, H., & Shapiro, L. (2005). A SIFT Descriptor with Global Context. 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), San Diego: IEEE.
- Munantri, N. Z., Sofyan, H., & Yanu F. M. (2019). Aplikasi Pengolahan Citra Digital Untuk Identifikasi Umur Pohon. *Telematika*, 16(2), 97-104.
- Narang, S. R., Jindal, M. K., Ahuja, S., & Kumar, M. (2020). On the recognition of Devanagari ancient handwritten characters using SIFT and Gabor features. *Soft Computing*, 24, 17279–17289.
- Naufal, M. F., Kusuma, S. F., Prayuska, Z. A., & Alexander, A. (2021). Comparative Analysis of Image Classification Algorithms for Face Mask Detection. *Journal of Information Systems Engineering and Business Intelligence*, 7(1), 56-66.
- Pradhan, A. (2012). Support Vector Machine-A Survey. *International Journal of Emerging Technology and Advanced Engineering*, 2(8), 82-85.
- Rajesh S., R., Beaula, A., Marikkannu, P., Sungheetha, A., & Sahana, C. (2016). Comparative study of distinctive image classification techniques. 2016 10th International Conference on Intelligent Systems and Control. Coimbatore: IEEE.
- Rajput, G. G. & Ummapure, S. B. (2017). Script Identification from Handwritten Documents using SIFT Method. *IEEE International Conference on Power, Control, Signals and Instrumentation Engineering* (pp. 520-526). Chennai: IEEE.
- Rasyidi, M. A., Bariyah, T., Riskajaya, Y. I., & Septyani, A. D. (2021). Classification of handwritten javanese script using random forest algorithm. *Bulletin of Electrical Engineering and Informatics*, 10 (3), 1308-1315.
- Rismiyati, Khadijah, & Adi, N. (2017). Deep learning for handwritten Javanese character recognition. 2017 1st International Conference on Informatics and Computational Sciences (pp. 59-63). Semarang: IEEE.
- Rismiyati, Khadijah, & Riyanto, D. (2018). HOG and Zone Base Features for Handwritten Javanese Character Classification. 2018 2nd International

Conference on Informatics and Computational Science (pp. 131-135). Semarang: IEEE.

- Robby, G. A., Tandra, A., Susanto, I., Harefa, J., & Chowanda, A. (2019). Implementation of Optical Character Recognition using Tesseract with the Javanese Script Target in Android Application. *Procedia Computer Science*, 157, 449-505.
- Saputra, A. C., Sitepu, A. B., Stanley, Yohanes Sigit, P. W. P., Sarto Aji Tetuko, P. G., & Nugroho, G. C. (2019). The Classification of the Movie Genre based on Synopsis of the Indonesian Film. *Proceeding - 2019 International Conference of Artificial Intelligence and Information Technology, ICAIIT 2019*, 201–204.
- Sari, C. A., Kuncoro, M. W., Setiadi, D. R. I. M., & Rachmawanto, E. H. (2018). Roundness and eccentricity feature extraction for Javanese handwritten character recognition based on K-nearest neighbor. *2018 International Seminar on Research of Information Technology and Intelligent Systems* (pp. 5-10). Yogyakarta: IEEE.
- Setiawan, A., Prabowo, A. S., & Puspaningrum, E. Y. (2019). Handwriting Character Recognition Javanese Letters Based on Artificial Neural Network. *International Journal of Computer, Network Security and Information System*, 1(1), 39-42.
- Setiawan, A., & Sulaiman, A. M. (2015). Hancaraka: Aksara Jawa Dalam Karakter Font dan Aplikasinya Sebagai Brand Image. *Ornamen Jurnal Kriya*, 12(1), 33-47.
- Sriwathsan, W., Ramanan, M., & Weerasinghe, A. R. (2020). Offline Handwritten Signature Recognition Based on SIFT and SURF Features Using SVMs. *Asian Research Journal of Mathematics*, 16(1), 84-91.
- Surinta, O., Karaaba, M. F., Schomaker, L. R. B., & Wiering, M. A. (2015). Recognition of handwritten characters using local gradient feature descriptors. *Engineering Applications of Artificial Intelligence*, 45, 405-414.
- Susanto, A., Sari, C. A., Mulyono, I. U. W., & Doheir, M. (2021). Histogram of Gradient in K-Nearest Neighbor for Javanese Alphabet Classification. *Scientific Journal of Informatics*, 8(2), 289-296.
- Thamilselvana, P., & Sathiaselvan, J. G. R. (2015). A Comparative Study of Data Mining Algorithms for Image Classification. *International Journal of Education and Management Engineering*, 5(2), 1-9.

- Wang, Y., Chen, J., Hu, B., Yang, X., & Ban, X. (2015). License plate recognition based on SIFT feature. *Optik - International Journal for Light and Electron Optics*, 126(21), 2895-2901.
- Wang, Y., Li, Z., Wang, L., & Wang, M. (2013). A Scale Invariant Feature Transform Based Method. *Journal of Information Hiding and Multimedia Signal Processing*, 4(2), 73-89.
- Wibowo, M. A., Soleh, M., Pradani, W., Hidayanto, A. N., & Arymurthy, A. M. (2017). Handwritten Javanese Character Recognition using Discriminative Deep Learning Technique. *2017 2nd International Conferences on Information Technology, Information Systems and Electrical Engineering* (pp. 325-330). Yogyakarta: IEEE.
- Widiarti, A. R., & Wastu, P. N. (2009). Javanese Character Recognition Using Hidden Markov Model. *International Journal of Computer and Information Engineering*, 3(9), 2201-2204.
- Yulianti, R., Wijaya, I. G. P. S., & Bimantoro, F. (2019). Pengenalan Pola Tulisan Tangan Suku Kata Aksara Sasak Menggunakan Metode Moment Invariant dan Support Vector Machine. *Journal of Computer Science and Informatics Engineering*, 3(2), 91-98.